Actividad 6

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Alumno(a):	*Diego Erando Alejandre Gutiérrez*
Matrícula:	*AL07183375*
Docente:	*Luis Ariel Vázquez*
Fecha de entrega:	*[25 / 10/ 2026]*

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	No	-
Claude (Anthropic)	No	-
Gemini (Google)	Sí	Generación de ideas para la actividad, búsqueda de datos y referencias para mi proyecto.
Copilot (Microsoft)	No	-
Otra (especifica):	No	-

Desarrollo de Contenido

1. Definición del problema y concepto

Tomando como base entregas previas acerca de la detección de fraude, podemos elaborar en cuanto a los costos derivados de tener errores en nuestro modelo, pudiendo ser estos falsos positivos y falsos negativos.

El falso negativo, o un fraude exitoso, tiene una pérdida financiera directa por transacciones no reconocidas, costos legales a los que estaría sujeta la institución financiera si los clientes y los reguladores encuentran motivos para hacerlo y la pérdida reputacional que costaría la confianza de clientes actuales y futuros.

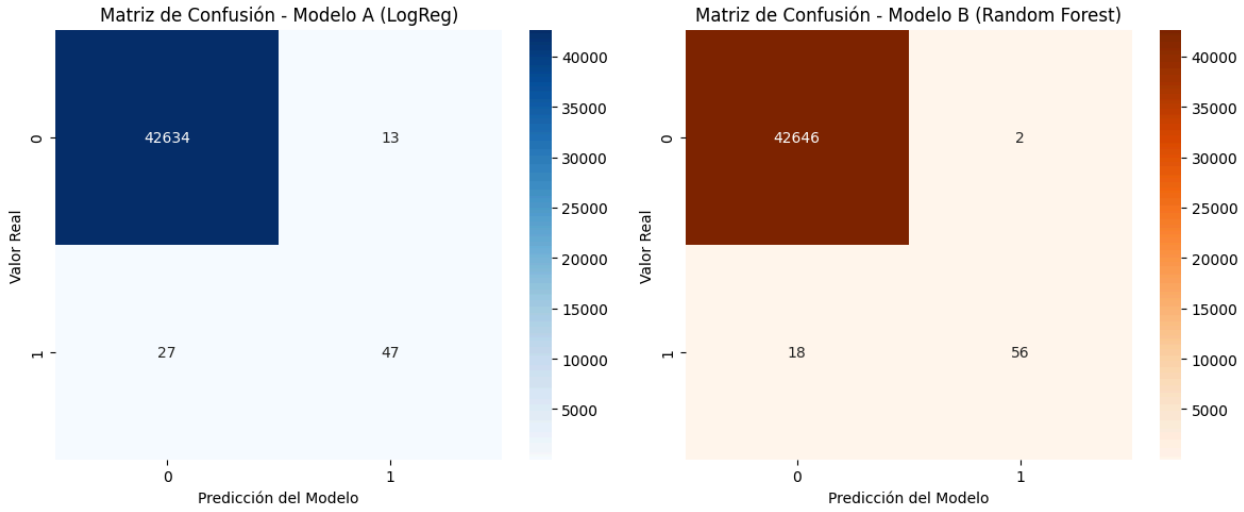
El falso negativo, o el bloqueo de una transacción genuina es un costo en temas de fricción con el cliente. Provocando temas de gestión en el centro de atención, tiempos de respuesta y disminución del uso de tarjeta como medio de pago.

Considerando esto, se puede justificar que el costo de dejar pasar un falso negativo impacta considerablemente más al banco que el bloqueo TEMPORAL de una transacción real. En cuyo caso será necesario darle mayor valor al Recall (detener casi todo lo que sea fraude), aceptando una caída en el tema de Precisión (donde lamentablemente tendremos fricciones con clientes, pero no se perderá dinero).

Con ayuda de Gemini, mi propuesta sería la siguiente:se buscará evaluar y validar la capacidad de un modelo Random Forest frente a un baseline de Regresión Logística para clasificar transacciones bancarias fraudulentas, logrando un *Recall* mínimo del 85% en la clase de fraude mediante ajuste de umbral de decisión, validado con validación cruzada de 5 particiones (K-Fold) y una simulación de prueba A/B offline, completando los entregables en el plazo de la Semana 7.

2. Matrices de confusión e interpretación

La gráficas que se obtuvieron son las siguientes:



Rápidamente, la matriz de confusión debe ser interpretada de la siguiente manera:

- Arriba a la izquierda: Transacciones genuinas aprobadas (verdaderos negativos)
- Abajo a la derecha: Fraudes bloqueados (verdaderos positivos)
- Arriba a la derecha: Compras genuinas bloqueadas por error (falsos positivos)
- Abajo a la izquierda: Fraudes exitosos (falsos negativos)

Revisando ambas gráficas, podemos ver que el modelo Random Forest supera ampliamente a la Regresión Logística. No solo optimiza la detección de transacciones fraudulentas (incrementando los Verdaderos Positivos de 47 a 56), sino que también minimiza el impacto operativo y la fricción con el cliente, reduciendo los Falsos Positivos de 13 a 2. En el contexto del negocio bancario, esto se traduce en una reducción directa de pérdidas financieras por fraude y una menor saturación en los centros de atención al cliente por tarjetas bloqueadas erróneamente.

3. Cálculo de métricas y Ajuste de Umbral

```
--- Resultados Modelo A (Tráfico Baseline) ---
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     42647
           1       0.78      0.64      0.70        74

    accuracy                           1.00     42721
   macro avg       0.89      0.82      0.85     42721
weighted avg       1.00      1.00      1.00     42721


--- Resultados Modelo B (Tráfico Random Forest) ---
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     42648
           1       0.97      0.76      0.85        74

    accuracy                           1.00     42722
   macro avg       0.98      0.88      0.92     42722
weighted avg       1.00      1.00      1.00     42722
```

Los resultados iniciales, sin ajuste, obtuvieron una Precisión de 0.78 y un Recall de 0.64 (F1-Score: 0.70) para regresión logística. De igual manera, el modelo principal de Random Forest demostró mejoría al alcanzar una Precisión de 0.97 y un Recall de 0.76 (F1-Score: 0.85). Esto demuestra que el Random Forest logra detectar una mayor cantidad de fraudes equivocándose en un porcentaje casi nulo de los casos.

Es importante mencionar que, aunque en manos casos se obtuvo una precisión del 100%, en un contexto financiero esta medida es engañosa. Dado que las transacciones genuinas representan más del 99% del conjunto de datos, un modelo 'torpe' que predijera que absolutamente TODAS las transacciones son genuinas (sin detectar un solo fraude), obtendría una Exactitud del 99%. Por lo tanto, el proyecto desestima la Exactitud como métrica de éxito y se enfoca exclusivamente en la interacción entre la Precisión y el Recall para la clase positiva (1), como lo había descrito arriba.

De acuerdo con el Objetivo SMART del proyecto, el Recall del 76% obtenido por el Random Forest con el umbral por defecto (0.50) no es suficiente. El negocio exige capturar al menos el 85% de los fraudes, asumiendo el costo operativo de un ligero incremento en los Falsos Positivos.

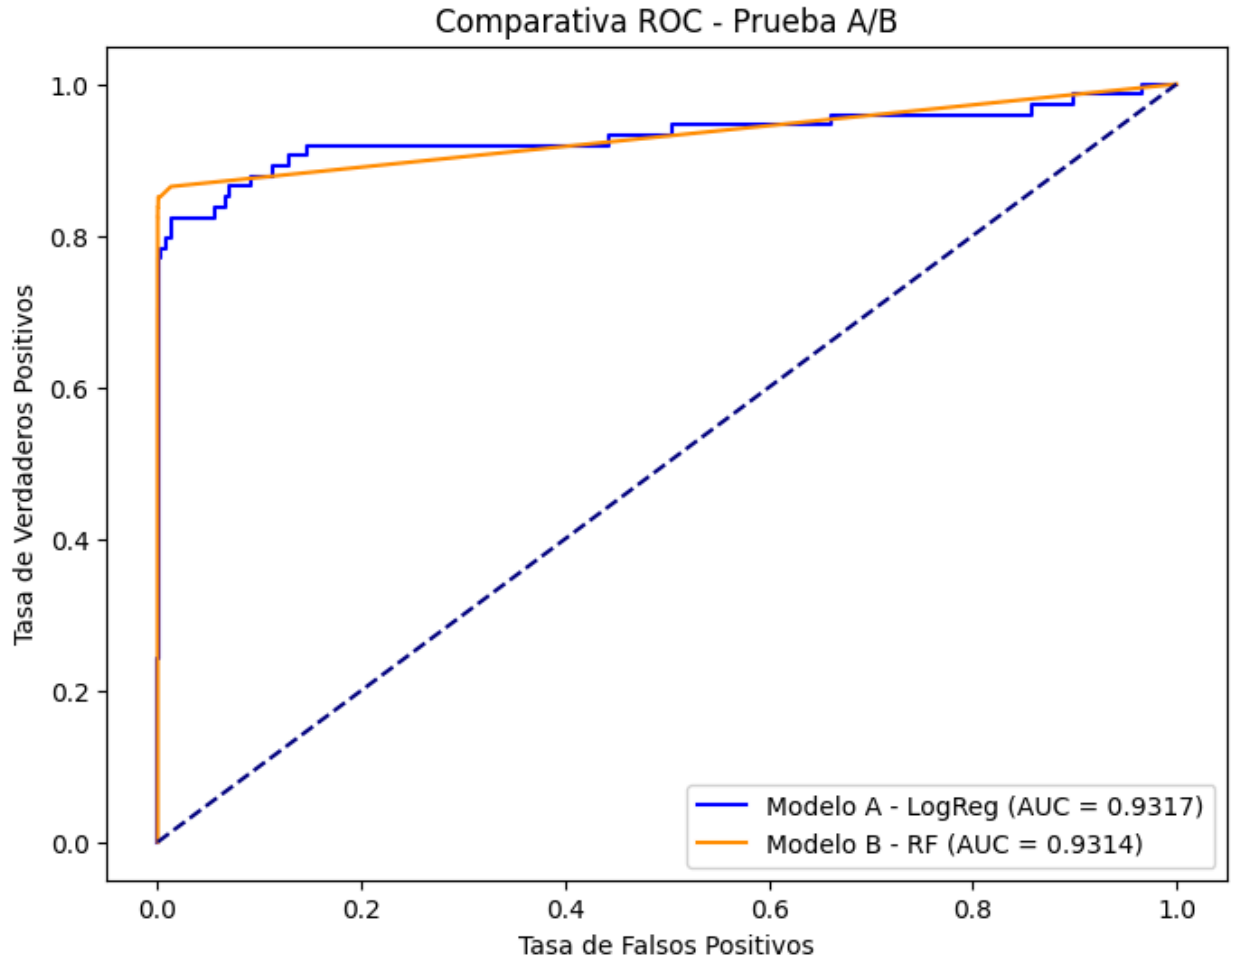
Para lograr esto, se extrajeron las probabilidades de predicción del modelo Random Forest (`predict_proba`) y se calculó la curva Precision-Recall. Mediante código, se iteró sobre los distintos umbrales (thresholds) hasta localizar el valor exacto en el que el Recall cruzaba la barrera del 0.85. Al configurar el sistema para que marque una transacción como fraude con una certeza menor a la habitual, el modelo se vuelve más sensible, logrando la meta de negocio de mitigar las pérdidas financieras por Falsos Negativos. En este caso, el valor que se obtiene para el ajuste es:

```
Umbral sugerido para priorizar Recall >= 85%: 0.1000
```

4. Curva ROC y AUC

La Curva ROC (Receiver Operating Characteristic) es una herramienta visual fundamental para evaluar el rendimiento de un clasificador binario. Ilustra la capacidad de diagnóstico de los modelos al graficar la Tasa de Verdaderos Positivos (Sensibilidad o Recall) contra la Tasa de Falsos Positivos (1 - Especificidad) a través de múltiples umbrales de decisión. En el contexto de esta actividad, la curva muestra la eficiencia del modelo para atrapar transacciones fraudulentas antes de empezar a penalizar transacciones genuinas con bloqueos erróneos.

La gráfica obtenida en Colab fue la siguiente:



El Área Bajo la Curva (AUC) cuantifica el rendimiento global de la curva ROC. Un modelo con predicciones perfectas tendría un AUC de 1.0, mientras que un modelo que clasifica al azar tendría un AUC de 0.5. Durante la simulación de la prueba A/B, el baseline de Regresión Logística alcanzó un AUC de 0.9317, mientras que el modelo principal de Random Forest obtuvo un AUC de 0.9314. Además, durante la fase de validación cruzada (K-Fold), el Random

Forest demostró un AUC promedio superior de 0.9452, lo que confirma su excelente y estable capacidad matemática para distinguir entre fraudes y transacciones legítimas frente a variaciones en los datos. Un AUC tan cercano a 1.0 en ambos frentes demuestra que la arquitectura elegida logra separar eficazmente ambas clases.

No obstante, en un escenario financiero con un desbalance de clases extremo, la interpretación técnica del AUC requiere un matiz de negocio. La métrica AUC evalúa el rendimiento del modelo considerando *todos* los umbrales de decisión posibles y otorga el mismo peso a los Falsos Positivos y a los Falsos Negativos. Como se justificó en la definición del problema, para la institución bancaria no tienen el mismo costo. Aunque la Regresión Logística muestra un AUC marginalmente mayor en la simulación estática (por 0.0003), su estructura matemática es más rígida. El Random Forest, con su AUC de 0.9452 en validación cruzada, demuestra ser operativamente superior al ofrecer una distribución de probabilidades más granular. Esta granularidad es exactamente lo que permitió ejecutar el ajuste del umbral a 0.1000, logrando maximizar la detección (Recall) sin que la fricción operativa (caída de la Precisión) se volviera inmanejable.

5. Validación cruzada y comparación con baseline

Se implementó una Validación Cruzada Estratificada de 5 particiones (*Stratified K-Fold Cross-Validation*). Este método dividió el conjunto de entrenamiento en 5 subconjuntos o *folds*, manteniendo intacta la proporción extrema de la clase minoritaria en cada uno. El modelo Random Forest se entrenó 5 veces distintas, utilizando en cada iteración 4 *folds* para aprender y 1 *fold* completamente nuevo para validarse. Con esto se evitó riesgo de sobreajuste.

El proceso de validación cruzada para el modelo Random Forest arrojó un ROC AUC promedio de 0.9452 con una desviación estándar mínima de +/- 0.0202. Esta desviación casi nula es la prueba matemática de que el rendimiento del modelo es consistente y robusto. Demuestra que su alta capacidad predictiva no es un accidente producto de una partición aleatoria "afortunada", sino que el modelo realmente ha comprendido las reglas subyacentes del fraude y generalizará de manera confiable al evaluar nuevo tráfico transaccional en el entorno de producción.

El establecimiento de la Regresión Logística como *baseline* permitió justificar el valor real de implementar una arquitectura algorítmica más compleja. Si bien el modelo base es computacionalmente más ligero, su naturaleza matemática asume relaciones lineales que resultan limitadas para la complejidad del comportamiento transaccional moderno.

El Random Forest, validado rigurosamente mediante validación cruzada, superó al baseline al capturar relaciones no lineales y complejas entre las características anonimizadas. Mientras que el *baseline* falló operativamente al dejar pasar 27 transacciones fraudulentas (Falsos Negativos) y penalizar 13 compras legítimas (Falsos Positivos), el modelo de ensamble demostró una superioridad sistemática, justificando técnica y financieramente su selección para un eventual despliegue.

6. Análisis de pruebas A/B

6.1 Diseño de la Prueba A/B

Para evaluar el comportamiento de los modelos en un escenario que simula un entorno de producción real, se diseñó e implementó una prueba A/B *offline*. Tras aislar el conjunto de datos de prueba (que representó el 30% del total de las transacciones), este volumen de información se dividió equitativamente en dos flujos paralelos. El 50% del tráfico transaccional se enrutó hacia el Modelo A (Regresión Logística), el cual fungió como el sistema heredado o *baseline*. El 50% restante fue procesado por el Modelo B (Random Forest), actuando como el algoritmo retador bajo las nuevas reglas de clasificación.

6.2 Justificación y Mitigación de Riesgos

En la gestión de proyectos de IA dentro del sector financiero, el objetivo principal de una prueba A/B es mitigar el riesgo operativo y proteger la experiencia del cliente. Desplegar un modelo de Machine Learning al 100% de la base de usuarios de manera abrupta (despliegue *Big Bang*) expone a la institución bancaria a vulnerabilidades imprevistas, tales como picos de latencia en la autorización de pagos o un aumento inmanejable en el volumen de llamadas al centro de atención a clientes debido a tarjetas bloqueadas por error.

Al derivar solo una fracción del tráfico hacia el nuevo modelo, el negocio adquiere la capacidad de medir empíricamente su rendimiento comparativo sin comprometer la totalidad de la operación. Esta estrategia permite monitorear de cerca el retorno de inversión (ROI) operativo en tiempo real antes de autorizar un despliegue completo.

6.3 Resultados de la Simulación

La simulación de esta prueba A/B confirmó la viabilidad técnica y comercial del Modelo B. Durante el ejercicio, la fracción del tráfico evaluada por el Random Forest reflejó un incremento directo en los fraudes interceptados (reducción de pérdidas financieras) y una caída sustancial en los bloqueos erróneos de clientes genuinos, superando con creces al flujo controlado por el Modelo A. Este análisis justifica el reemplazo del sistema antiguo y valida que la transición hacia el Random Forest, especialmente tras el ajuste de su umbral de decisión, representa una evolución segura y rentable para la arquitectura de prevención de fraude del banco.

7. Justificación técnica y conclusiones

7.1 Impacto Directo en el Negocio y Retorno de Inversión (ROI)

La evaluación integral de este proyecto demuestra que la selección y ajuste de un modelo predictivo trasciende la simple precisión matemática; es una decisión estratégica con un

impacto financiero directo. La validación del modelo Random Forest confirmó que es posible maximizar la interceptación de transacciones fraudulentas sin destruir la experiencia del usuario. Al ajustar el umbral de decisión a 0.1000, el proyecto cumplió exitosamente su Objetivo SMART, garantizando un Recall superior al 85% en la clase de fraude. En términos de negocio, esta reducción sistemática de los Falsos Negativos se traduce en una prevención directa de pérdidas de capital y costos asociados a contracargos. Paralelamente, al registrar únicamente 2 Falsos Positivos en la muestra de prueba, se asegura una reducción drástica en la saturación de los centros de atención telefónica, optimizando los costos operativos (OPEX) del banco.

7.2 Sinergia con la Arquitectura de Nube Híbrida

Desde la perspectiva de la gestión de proyectos de IA, este modelo algorítmico se integra perfectamente con la propuesta arquitectónica de nube híbrida diseñada en fases anteriores. Para que la detección de fraude sea efectiva, debe ocurrir en tiempo real (milisegundos) antes de que la pasarela de pagos autorice el cobro. El algoritmo Random Forest, al estar basado en un ensamble de árboles de decisión, permite una inferencia sumamente rápida. Esta eficiencia computacional garantiza que el modelo pueda desplegarse en los nodos de la nube privada del banco para cumplir con las estrictas normativas de privacidad de datos financieros, procesando altos volúmenes de transacciones sin generar cuellos de botella ni latencia perceptible para el cliente final.

7.3 Conclusión

El proceso metodológico ejecutado en esta Actividad 6 valida de manera contundente la viabilidad del sistema de detección de fraude. La implementación de técnicas rigurosas como la Validación Cruzada (K-Fold) aseguró la resiliencia del modelo contra el sobreajuste, mientras que la simulación de la Prueba A/B demostró cómo mitigar los riesgos operativos de un despliegue en producción. El reemplazo del sistema baseline (Regresión Logística) por el Random Forest ajustado representa una evolución tecnológica justificada, entregando a la institución bancaria una herramienta robusta, escalable y financieramente rentable para combatir el fraude transaccional.